数据集

- Dataset的收集方式:
 - The expert annotators reviewed 50 second long EEG samples plus matched spectrograms covering 10 a minute window centered at the same time and labeled the central 10 seconds.
- Files
 - data里一共两种文件csv和parquet
 - data里面的csv文件是metadata.
 - raw data是spectrograms和eegs文件夹里面的parquet文件.metadata决定了怎么构造samples
- visualize raw data的可以参考笔记本

https://www.kaggle.com/code/mikhailzemskov/understanding-stft-and-spectrograms https://www.kaggle.com/code/cdeotte/how-to-make-spectrogram-from-eeg/notebook

- dataset 构造可以用
- HMS-HBAC: KerasCV Starter Notebook (这个notebook主要是extract samples的code) https://www.kaggle.com/code/awsaf49/hms-hbac-kerascv-starter-notebook/notebook

spectrograms data:

每个parquet文件都以唯一的spectrogram id命名。

dataframe 的columns 一共有401个,第一个col是time,其余column代表探头?每个探头分别有10个columns。见图。

dataframe (df_spec) 长度为 320 (注意time column 全是奇数 最大的time stamps是639)

```
df_spectrogram = pd.read_parquet(SPECTROGRAM_SAMPLE_FILE)
df_spectrogram.head(10)
```

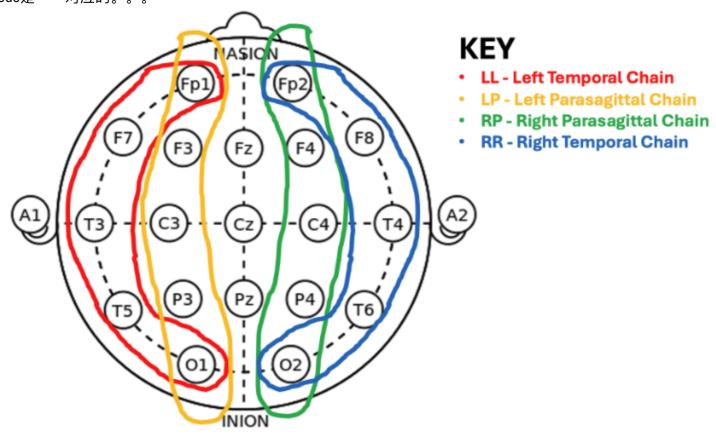
	time	LL_0.59	LL_0.78	LL_0.98	LL_1.17	LL_1.37	LL_1.56	LL_1.76	LL_1.95	LL_2.15	 RP_
0	1	4.26	10.98	9.05	13.65	11.49	8.930000	18.840000	19.26	19.240000	 0.31
1	3	2.65	3.97	12.18	13.26	14.21	13.230000	9.650000	8.11	11.280000	 0.15
2	5	4.18	4.53	8.77	14.26	13.36	16.559999	19.219999	17.51	22.650000	 0.29
3	7	2.41	3.21	4.92	8.07	5.97	12.420000	10.820000	14.96	21.809999	 0.33
4	9	2.29	2.44	2.77	4.62	5.39	7.080000	9.840000	12.27	14.410000	 0.44

eeg data:

每个parquet文件都以唯一的eeg id命名。

dataframe 的columns 除了没有time column, 其余和spectrograms类似,见表格。这里我只能大胆猜测electro

node是一一对应的。。。



dataframe (df_egg) 长度为18000

Q: 因为eeg和spectrogram是matched的,但是time stamps数目不一样。time stamps是不同的单位吗?分别是什么单位Z?

```
df_eeg = pd.read_parquet(EEG_SAMPLE_FILE)
df_eeg.head(10)
```

	Fp1	F3	C3	P3	F7	T3	T5	01
0	-80.519997	-70.540001	-80.110001	-108.750000	-120.330002	-88.620003	-101.750000	-104.4899
1	-80.449997	-70.330002	-81.760002	-107.669998	-120.769997	-90.820000	-104.260002	-99.73000
2	-80.209999	-75.870003	-82.050003	-106.010002	-117.500000	-87.489998	-99.589996	-96.82000
3	-84.709999	-75.339996	-87.480003	-108.970001	-121.410004	-94.750000	-105.370003	-100.2799
4	-90.570000	-80.790001	-93.000000	-113.870003	-129.960007	-102.860001	-118.599998	-101.0999

metadata: 来自train.csv 基本上规定了sample的构造(见下一节)<input, label> pair

```
df_metadata = pd.read_csv(METADATA_PATH)
df_metadata.head(10)
```

	eeg_id	eeg_sub_id	eeg_label_offset_seconds	spectrogram_id	spectrogram_sub_id	spectrogram_label_c
0	1628180742	0	0.0	353733	0	0.0
1	1628180742	1	6.0	353733	1	6.0
2	1628180742	2	8.0	353733	2	8.0
3	1628180742	3	18.0	353733	3	18.0
4	1628180742	4	24.0	353733	4	24.0

Dataset的构造 <input,label> pair

(个人理解)

- 在train.csv文件里面记录了每一个sample和对应的label。每个sample对应着一个spectrogram id, eeg id, eeg_sub_id(spectrogram_sub_id), eeg_label_offset_seconds(spectrogram_label_offset_seconds), label_id, votes...等等
- 假设df_spec_id1是对应某个spectrogram_id的数据,那么对应每一个offset,我们能从这个dataframe中 提取一个sample df_spec_id1[:, offset : offset+320]。
- 一共能提取的samples是 df_spec_id1[:, offset : offset+320] for offset in metadata[metadata.spectrogram_id == id1]['spectrogram_label_offset_seconds']]
- eeg的sample input构造同理。且与每一个spectrogram sample input对应。这个对应是有csv里面的对应 确定的。
- Question: metadata里面, 对应同一个sample, eeg_label_offset_seconds 和 spectrogram_label_offset_seconds 的值有时候是相同的 有时候是不同的。。。我不是太理解。。。 而且看eeg和spectrogram的长度是不同的, 鉴于它们都是同一个时间段matched的pair 所以我推测对应 的时间单位是不一样的。如果时间单位不一样,我的理解是eeg和spectrogram的offset应该是成比例才 对。。。不是吗。。。?

notes

大致看了一下各种notebooks。一部分在折腾features,譬如eeg那几列数据的交互作用;一部分在做各种信号处理 (signal processing),包括去噪 各种傅立叶变换 小波变换。一部分在搞CV model。。。。

-----03-13

https://zhuanlan.zhihu.com/p/147561580 https://zhuanlan.zhihu.com/p/549254941

https://blog.csdn.net/youzi12345678/article/details/89321276?

spm=1001.2101.3001.6650.2&utm_medium=distribute.pc_relevant.none-task-blog2%7Edefault%7ECTRLIST%7ERate-2-89321276-blog-85716900.235%5Ev43%5Econtrol&depth_1utm_source=distribute.pc_relevant.none-task-blog-2%7Edefault%7ECTRLIST%7ERate-2-89321276-blog85716900.235%5Ev43%5Econtrol&utm_relevant_index=5

https://blog.csdn.net/weixin_44086494/article/details/105881174?

spm=1001.2101.3001.6650.6&utm_medium=distribute.pc_relevant.none-task-blog2%7Edefault%7EBlogCommendFromBaidu%7ERate-6-105881174-blog-85716900.235%5Ev43%5Econtrol&depth_1utm_source=distribute.pc_relevant.none-task-blog-2%7Edefault%7EBlogCommendFromBaidu%7ERate-6105881174-blog-85716900.235%5Ev43%5Econtrol&utm_relevant_index=10